2/5/2020 OneNote

## MapReduce

miércoles, 29 de abril de 2020 15:36

Ejecutar y registrar en bitacora ejemplo de wordcount-local.py y en MapReduce con mrjob de wordcount-mr.py en versión LOCAL

o Local

o Mrjob

Ejecutar y registrar en bitacora ejemplo de wordcount-mr.py en HADOOP (datos de entrada y salida en HDFS en el DCA y en EMR)

Al crear las variables de ambiente y ejecutar el comando del Github se me creo la carpeta temp pero no la carpeta result



Name >	Size >	Last Modified >	Owner >	Group >	Permission Erasure Coding
•					
□ datasets		2020-03-27 22:16	amartinezv	bigdata	drwxr-xr-x
□ tmp		2020-04-13 13:17	amartinezv	bigdata	drwxr-xr-x

- Ejercicios de mrjob dejados en el github
  - 1. Se tiene un conjunto de datos, que representan el salario anual de los empleados formales en Colombia por sector económico, según la DIAN.
    - 1. El salario promedio por Sector Económico (SE)



```
class PromedioSalarioSE(MRJob):
        def mapper(self, _, line):
   idemp, sececon, salary, year = line.split(',')
6
7
             try:
                 salary = float(salary)
             except ValueError:
10
                pass
11
12
13
            else:
                yield sececon, salary
15
16
17
        def reducer (self, sececon, salario):
            sumSalario=0
             cont =0
18
19
            for s in salario:
                sumSalario += s
20
                cont += 1
21
22
            yield sececon, sumSalario/cont
23
                == ' main_
   if __name_
        PromedioSalarioSE.run()
```

```
[amartinezv@hdpjupyter ~]$ python PromedioSalarioSE.py bigdata/datasets/otros/dataempleados.csv. No configs found; falling back on auto-configuration
No configs specified for inline runner
Creating temp directory /tmp/PromedioSalarioSE.amartinezv.20200413.201225.733947
Running step 1 of 1...
job output is in /tmp/PromedioSalarioSE.amartinezv.20200413.201225.733947/output
Streaming final output from /tmp/PromedioSalarioSE.amartinezv.20200413.201225.733947/output...
"1212" 77000.0
"1234" 37500.0
"1412" 76000.0
"3432" 34000.0
   3432" 34000.0
5434" 36000.0
  Removing temp directory /tmp/PromedioSalarioSE.amartinezv.20200413.201225.733947...
[amartinezv@hdpjupyter ~]$
```

2. El salario promedio por Empleado

## Jupyter PromedioSalarioEmpleados.py ✓ hace unos segundos

```
Edit
File
            View
                     Language
   from mrjob.job import MRJob
   class PromedioSalarioEmpleados(MRJob):
       def mapper(self, _, line):
            idemp, sececon, salary, year = line.split(',')
7
8
               salary = float(salary)
9
           except ValueError:
10
               pass
11
            else:
               yield idemp, salary
12
13
14
15
      def reducer (self, idemp, salario):
16
           sumSalario=0
17
           cont =0
18
            for s in salario:
19
               sumSalario += s
20
               cont += 1
21
22
           yield idemp, sumSalario/cont
23
24 | if __name__ == '__main__':
       PromedioSalarioEmpleados.run()
```

```
[amartinezv@hdpjupyter ~]$ python PromedioSalarioEmpleados.py bigdata/datasets/otros/dataempleados.csv
No configs found; falling back on auto-configuration
No configs specified for inline runner
Creating temp directory /tmp/PromedioSalarioEmpleados.amartinezv.20200413.201858.308225
Running step 1 of 1...
job output is in /tmp/PromedioSalarioEmpleados.amartinezv.20200413.201858.308225/output
Streaming final output from /tmp/PromedioSalarioEmpleados.amartinezv.20200413.201858.308225/output
71115" 62333.33333333336
73233" 35500.0
73237" 40000.0
Removing temp directory /tmp/PromedioSalarioEmpleados.amartinezv.20200413.201858.308225...
[amartinezv@hdpjupyter ~]$
                                                                                            ~]$ python PromedioSalarioEmpleados.py bigdata/datasets/otros/dataempleados.csv
```

3. Número de SE por Empleado que ha tenido a lo largo de la estadística

2/5/2020 OneNote

```
jupyter NumeroSEporEmpleados.py→ hace un minuto
File
    Edit View
                 Language
1 from mrjob.job import MRJob
   class NumeroSEporEmpleados(MRJob):
       def mapper(self, _, line):
           idemp, sececon, salary, year = line.split(',')
              salary = float(salary)
8
           except ValueError:
9
10
              pass
           else:
12
              yield idemp, sececon
14
15
       def reducer (self, idemp, sector):
16
           cont =0
           for s in sector:
18
             cont += 1
19
20
          yield idemp, cont
21
  if __name__ == '__main__':
22
       NumeroSEporEmpleados.run()
```

```
[amartinezv@hdpjupyter ~]$ python NumeroSEporEmpleados.py bigdata/datasets/otros/dataempleados.csv
No configs found; falling back on auto-configuration
No configs specified for inline runner
No contigs specified for inline runner
Creating temp directory /tmp/NumerosEporEmpleados.amartinezv.20200413.202551.910763
Running step 1 of 1...
job output is in /tmp/NumerosEporEmpleados.amartinezv.20200413.202551.910763/output
Streaming final output from /tmp/NumerosEporEmpleados.amartinezv.20200413.202551.910763/output...
"1115" 3
"3233" 2
"3237" 1
Removing temp directory /tmp/NumeroSEporEmpleados.amartinezv.20200413.202551.910763... [amartinezv\thetahdpjupyter \sim]$
```